支持向量机(Support Vector Machine)-----SVM之SMO算法(转)

此文转自两篇博文 有修改

序列最小优化算法（英语：Sequential minimal optimization, SMO）是一种用于解决支持向量机训练过程中所产生优化问题的算法。SMO由微软研究院的约翰·普莱特（John Platt）发明于1998年，目前被广泛使用于SVM的训练过程中，并在通行的SVM库libsvm中得到实现。

1998年，SMO算法发表在SVM研究领域内引起了轰动，因为先前可用的SVM训练方法必须使用复杂的方法，并需要昂贵的第三方二次规划工具。而SMO算法较好地避免了这一问题。

前面最后留下来一个对偶函数最后的优化问题，原式为：

$$max\ W(\alpha)=\sum_{i=1}^{n}\alpha-\frac{1}{2}\sum_{i,j=1}^{n}y_iy_j\alpha_i\alpha_j(K(x_i,x_j))$$

-----------------这个是由拉格朗日方法 然后求偏导 列式带入核函数得到的目标函数

$$s.t.\qquad \sum_{i=1}^{n}y_i\alpha_i=0$$

$$0\leq\alpha_i\leq C$$

SMO就是要解这个凸二次规划问题，这里的C是个很重要的参数，它从本质上说是用来折中经验风险和置信风险的，C越大，置信风险越大，经验风险越小；并且所有的α因子都被限制在了以C为边长的大盒子里。

算法详述

(1)、 KKT条件

SMO是以C-SVC的KKT条件为基础进行后续操作的，这个KKT条件是：

$$\alpha_i=0\Leftrightarrow y_iu_i\geq1$$

$$0\leq\alpha_i\leq C\Leftrightarrow y_iu_i=1$$

$$\alpha_i=C\Leftrightarrow y_iu_i\leq1$$

其中$u_i=<w,x_i>+b$

上述条件其实就是KT互补条件，SVM学习——软间隔优化一文，有如下结论：

$$\alpha_i(y_i(<w,x_i>+b)-1+\xi_i)=0\ (i=1,2,...n)$$

$$\mu_i\xi_i=(\alpha_i-C)\xi_i=0\ (i=1,2,\ldots n)$$

从上面式子可以得到的信息是：当$\alpha_i=C$时，松弛变量$\xi_i\geq 0$，此时有：$y_i(\langle w,x_i\rangle+b)=1-\xi_i\Rightarrow y_i(\langle w,x_i\rangle+b)\leq 1\Rightarrow y_iu_i\leq 1$，对应样本点就是误分点；当$\alpha_i=0$时，松弛变量$\xi_i$为零，此时有$y_i(\langle w,x_i\rangle+b)\geq 1\Rightarrow y_iu_i\geq 1$，对应样本点就是内部点，即分类正确而又远离最大间隔分类超平面的那些样本点；而$0<\alpha_i<C$时，松弛变量ξ_i为零，有$y_i(\langle w,x_i\rangle+b)=1\Rightarrow y_iu_i=1$，对应样本点就是支持向量。

(2)、凸优化问题停止条件

对于凸优化问题，在实现时总需要适当的停止条件来结束优化过程，停止条件可以是：

1、监视目标函数$W(\alpha)$的增长率，在它低于某个容忍值时停止训练，这个条件是最直白和简单的，但是效果不好；

2、监视原问题的KKT条件，对于凸优化来说它们是收敛的充要条件，但是由于KKT条件本身是比较苛刻的，所以也需要设定一个容忍值，即所有样本在容忍值范围内满足KKT条件则认为训练可以结束；

3、监视可行间隙，它是原始目标函数值和对偶目标函数值的间隙，对于凸二次优化来说这个间隙是零，以一阶范数软间隔为例：

原始目标函数$O(w,b)$与对偶目标函数$W(\alpha)$的差为：

$$Gap=\frac{1}{2}\langle w,w\rangle+C\sum_{i=1}^{n}\xi_i-\left(\sum_{i=1}^{n}\alpha-\frac{1}{2}\sum_{i,j=1}^{n}y_iy_j\alpha_i\alpha_j(K(x_i,x_j))\right)$$

$$=\frac{1}{2}\sum_{i,j=1}^{n}y_iy_j\alpha_i\alpha_jK(x_i,x_j)+C\sum_{i=1}^{n}\xi_i-\left(\sum_{i=1}^{n}\alpha_i-\frac{1}{2}\sum_{i,j=1}^{n}y_iy_j\alpha_i\alpha_j(K(x_i,x_j))\right)$$

$$=\sum_{i,j=1}^{n}y_iy_j\alpha_i\alpha_jK(x_i,x_j)+C\sum_{i=1}^{n}\xi_i-\sum_{i=1}^{n}\alpha_i$$

$$=2\sum_{i=1}^{n}\alpha_i-2W(\alpha)+C\sum_{i=1}^{n}\xi_i-\sum_{i=1}^{n}\alpha_i$$

$$=\sum_{i=1}^{n}\alpha_i-2W(\alpha)+C\sum_{i=1}^{n}\xi_i$$

定义比率：

$$\frac{O(w,b)-W(\alpha)}{O(w,b)+1}$$

，可以利用这个比率达到某个容忍值作为停止条件。

(3)、**SMO**思想

沿袭分解思想，固定"Chunking工作集"的大小为2，每次迭代只优化两个点的最小子集且可直接获得解析解，算法流程：

2013年5月 (1)
2012年11月 (4)
2012年10月 (7)
2012年9月 (17)
2012年8月 (59)
2012年7月 (59)

最新评论

1. Re:决策树算法总结
J48是c4.5的java开源实现。
--zqiguoshang
2. Re:TF-IDF及其算法
很清楚
--Princeling
3. Re:最小生成树-Prim算法和Kruskal算法
大神，可以抱走吗
--漠漠残香
4. Re:编辑距离及编辑距离算法
终于找到一个列出数组的，学习了，谢谢楼主！
--hylights
5. Re:最短路径—Dijkstra算法和Floyd算法
话不多说，一个字，好！
--屌丝改变世界

阅读排行榜

1. 最短路径—Dijkstra算法和Floyd算法(81707)
2. 决策树算法总结(42740)
3. HTTP请求报文和HTTP响应报文(34470)
4. 最小生成树-Prim算法和Kruskal算法(32252)
5. Logistic Regression--逻辑回归算法汇总**(31316)

评论排行榜

1. 最短路径—Dijkstra算法和Floyd算法(15)
2. C++ STL中的vector的内存分配与释放(7)
3. 编辑距离及编辑距离算法(5)
4. 排序算法汇总总结(5)
5. 决策树算法总结(4)

推荐排行榜

1. 最短路径—Dijkstra算法和Floyd算法(29)
2. HTTP请求报文和HTTP响应报文(9)
3. 信号量、互斥体和自旋锁(8)
4. Logistic Regression--逻辑回归算法汇总**(7)
5. Linux写时拷贝技术(copy-on-write)(6)

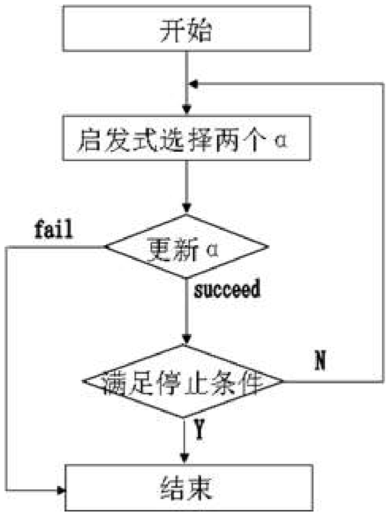

(4)、仅含两个**Langrange**乘子解析解

为了描述方便定义如下符号：

$$K_{ij}=K(\boldsymbol{x_i},\boldsymbol{x_j})$$

$$f(\boldsymbol{x_i})=\sum_{j=1}^{n}y_i\alpha_iK_{ij}+b$$

$$v_i=\sum_{j=3}^{n}y_j\alpha_jK_{ij}=f(\boldsymbol{x_i})-\sum_{j=1}^{2}y_j\alpha_jK_{ij}-b$$

于是目标函数就变成了：

$$W(\alpha_2)=\sum_{i=1}^{n}\alpha_i-\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}y_iy_jK(x_i,x_j)\alpha_i\alpha_j$$

$$=\alpha_1+\alpha_2+\sum_{i=3}^{n}\alpha_i-\frac{1}{2}\sum_{i=1}^{n}(\sum_{j=1}^{2}y_iy_j\alpha_i\alpha_jK(x_ix_j)+\sum_{j=3}^{n}y_iy_j\alpha_i\alpha_jK(x_ix_j))$$

$$=\alpha_1+\alpha_2+\sum_{i=3}^{n}\alpha_i-\frac{1}{2}\sum_{i=1}^{2}(\sum_{j=1}^{2}y_iy_j\alpha_i\alpha_jK(x_ix_j)+\sum_{j=3}^{n}y_iy_j\alpha_i\alpha_jK(x_ix_j))$$

$$-\frac{1}{2}\sum_{i=3}^{n}(\sum_{j=1}^{2}y_iy_j\alpha_i\alpha_jK(x_ix_j)+\sum_{j=3}^{n}y_iy_j\alpha_i\alpha_jK(x_ix_j))$$

$$=\alpha_1+\alpha_2+\sum_{i=3}^{n}\alpha_i-\frac{1}{2}\sum_{i=1}^{2}\sum_{j=1}^{2}y_iy_j\alpha_i\alpha_jK(x_ix_j)-\sum_{i=1}^{2}\sum_{j=3}^{n}y_iy_j\alpha_i\alpha_jK(x_ix_j)$$

$$-\frac{1}{2}\sum_{i=3}^{n}\sum_{j=3}^{n}y_iy_j\alpha_i\alpha_jK(x_ix_j)$$

$$=\alpha_1+\alpha_2-\frac{1}{2}K_{11}\alpha_1^2-\frac{1}{2}K_{22}\alpha_2^2-y_1y_2K_{12}\alpha_1\alpha_2$$

$$-y_1\alpha_1\sum_{j=3}^{n}y_j\alpha_jK(x_1x_j)-y_2\alpha_2\sum_{j=3}^{n}y_j\alpha_jK(x_2x_j)$$

$$+\sum_{i=3}^{n}\alpha_i-\frac{1}{2}\sum_{i=3}^{n}\sum_{j=3}^{n}y_iy_j\alpha_i\alpha_jK(x_ix_j)$$

$$=\alpha_1+\alpha_2-\frac{1}{2}K_{11}\alpha_1^2-\frac{1}{2}K_{22}\alpha_2^2-y_1y_2K_{12}\alpha_1\alpha_2$$
$$-y_1\alpha_1v_1-y_2\alpha_2v_2+\text{constant}$$

注意第一个约束条件：$\sum_{i=1}^{n}y_i\alpha_i=0$，可以将$\alpha_3,\cdots,\alpha_n,y_3,\cdots,y_n$看作常数，有$\alpha_1y_1+\alpha_2y_2=C'$($C'$为常数，我们不关心它的值)，等式两边同时乘以$y_1$，得到$\alpha_1=\gamma-s\alpha_2$（$\gamma$为常数，其值为$C'y_1$，我们不关心它，$s=y_1y_2$）。将$\alpha_1$用上式替换则得到一个只含有变量$\alpha_2$的求极值问题：

$$W(\alpha_2)=\gamma-s\alpha_2+\alpha_2-\frac{1}{2}K_{11}(\gamma-s\alpha_2)^2-\frac{1}{2}K_{22}\alpha_2^2$$

$$-sK_{12}(\gamma-s\alpha_2)\alpha_2-y_1(\gamma-s\alpha_2)v_1-y_2\alpha_2v_2+\text{constant}$$

这下问题就简单了，对α_2求偏导数得到：

$$\frac{\partial W(\alpha_2)}{\partial\alpha_2}=-s+1+sK_{11}\gamma-K_{11}\alpha_2-K_{22}\alpha_2-s\gamma K_{12}+2K_{12}\alpha_2+y_2v_1-y_2v_2=0$$

将$y_2^2=1$、$s=y_1y_2$带入上式有：

$$\alpha_2^{new}=\frac{y_2(y_2-y_1+y_1\gamma(K_{11}-K_{12})+v_1-v_2)}{K_{11}+K_{22}-2K_{12}}$$

带入v_i、$\gamma=\alpha_1^{old}+s\alpha_2^{old}$，用$E_i=f(\boldsymbol{x}_i)-y_i$，表示误差项(可以想象，即使分类正确，$f(x_i)$的值也可能很大)、$\eta=K_{11}+K_{22}-2K_{12}=\|\Phi(x_1)-\Phi(x_2)\|^2$($\Phi$是原始空间向特征空间的映射)，这里$\sqrt{\eta}$可以看成是一个度量两个样本相似性的距离，换句话说，一旦选择核函数则意味着你已经定义了输入空间中元素的相似性。

最后得到迭代式：

$$\alpha_2^{new}=\alpha_2^{old}+\frac{y_2(E_1-E_2)}{\eta}$$

注意第二个约束条件——那个强大的盒子：$0\le\alpha_i\le C$，这意味着α_2^{new}也必须落入这个盒子中，综合考虑两个约束条件，下图更直观：

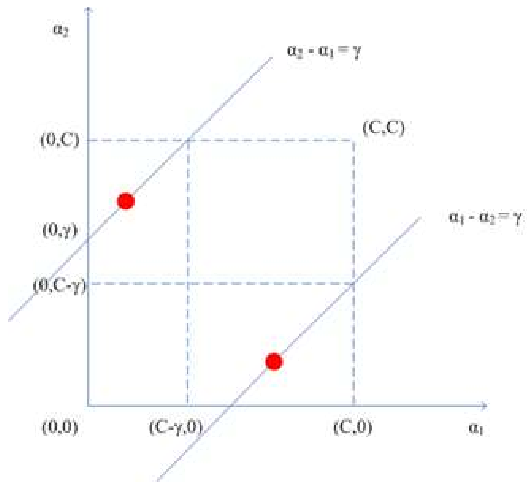

y_1和y_2异号的情形

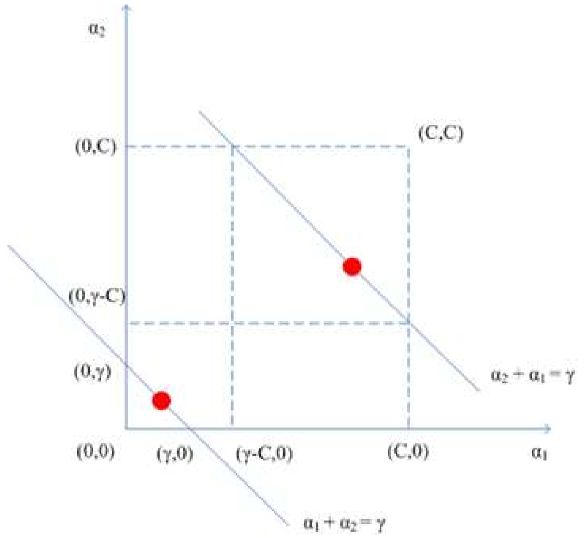

y_1和y_2同号的情形

可以看到α_1,α_2两个乘子既要位于边长为C的盒子里又要在相应直线上，于是对于α_2的界来说，有如下情况：

$$\begin{cases} L = max\{0, \alpha_2^{old} - \alpha_1^{old}\} & y_1 y_2 = -1, \\ L = max\{0, \alpha_1^{old} + \alpha_2^{old} - C\} & y_1 y_2 = 1, \end{cases}$$

$$\begin{cases} H = min\{C, C + \alpha_2^{old} - \alpha_1^{old}\} & y_1 y_2 = -1 \\ H = min\{C, \alpha_1^{old} + \alpha_2^{old}\} & y_1 y_2 = 1 \end{cases}$$

整理得下式：

$$\alpha_2^{new,clipped} = \begin{cases} L & \alpha_2^{new} \le L \\ \alpha_2^{new} & L < \alpha_2^{new} < H \\ H & \alpha_2^{new} \ge H \end{cases}$$

又因为$\alpha_1^{old} = \gamma - s\alpha_2^{old}$，$\alpha_1^{new} = \gamma - s\alpha_2^{new,clipped}$，消去$\gamma$后得到：

$$\alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new,clipped})$$

(5).综上可总结出**SMO**的算法框架

SMO算法是一个迭代优化算法。在每一个迭代步骤中，算法首先选取两个待更新的向量，此后分别计算它们的误差项，并根据上述结果计算出α_2^{new}和α_1^{new}。最后再根据SVM的定义计算出偏移量$\mathbf{b}$。对于误差项而言，可以根据α_1^{new}、α_2^{new}和b的增量进行调整，而无需每次重新计算。具体的算法如下：

1. 随机数初始化向量权重α_i，并计算偏移b。(这一步初始化向量权重只要使α_i符合上述的约束条件即可，原博文的程序就是range函数)

2.初始化误差项E_i，其中

$$E_i = f(\boldsymbol{x}_i) - y_i$$

$$f(\boldsymbol{x}_i) = \sum_{j=1}^{n} y_i \alpha_i K_{ij} + b$$

3.选取两个向量作为需要调整的点（例如第一次下标为1，2两点，第二次下标3，4..........），然后

令$\alpha_2^{new} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta}$其中$\eta = K_{11} + K_{22} - 2K_{12} = \|\Phi(x_1) - \Phi(x_2)\|^2$($\Phi$是原始空间向特征空间的映射)，$K_{ij} = K(\boldsymbol{x_i}, \boldsymbol{x_j})$

4.if α_2^{new}>H 令α_2^{new}=H *if* α_2^{new}<L 令α_2^{new}=L （L，H前面已给出）

5.令$\alpha_1^{new} = \alpha_1^{old} + y_1 y_2(\alpha_2^{old} - \alpha_1^{old})$

6.利用更新的α_1^{new}和α_2^{new}修改E_i和b的值

7.如果达到终止条件，则算法停止，否则转向3

算法补充说明：

优化向量选择方法

可以采用启发式的方法选择每次迭代中需要优化的向量。第一个向量可以选取不满足支持向量机KKT条件的向量，亦即不满足

$$y_i f(\mathbf{x}_i)\begin{cases} > 1 & \alpha_i = 0 \\ = 1 & 0 < \alpha_1 < C \\ < 1 & \alpha_i = C \end{cases}$$

即：

$$\alpha_i = 0 \Leftrightarrow y_i u_i \ge 1$$

$$0 \le \alpha_i \le C \Leftrightarrow y_i u_i = 1$$

$$\alpha_i = C \Leftrightarrow y_i u_i \le 1$$

其中$u_i = <w, x_i> + b$

的向量。而第二个向量可以选择使得$|E_1 - E_2|$最大的向量。

终止条件

SMO算法的终止条件可以为KKT条件对所有向量均满足，或者目标函数$W(\alpha)$增长率小于某个阈值，即

$$\frac{W(\alpha^{t+1}) - W(\alpha^t)}{W(\alpha^t)} < T$$

（根据前面的凸优化问题停止条件所说，此效果可能不佳，可选择其他方法,见(2)）

--------------------------------以下内容是有关可行间隙方法，乘子优化，SMO加速问题，是深化的内容---

(6)、启发式的选择方法

根据选择的停止条件可以确定怎么样选择点能对算法收敛贡献最大，例如使用监视可行间隙的方法，一个最直白的选择就是首先优化那些最违反**KKT**条件的点，所谓违反KKT条件是指：

$$\alpha_i = 0 \ \&\& \ y_i u_i < 1$$

$$0 \le \alpha_i \le C \ \&\& \ y_i u_i \ne 1$$

$$\alpha_i = C \ \&\& \ y_i u_i > 1$$

其中KKT条件

$$\begin{aligned} \alpha_i = 0 &\Leftrightarrow y_i u_i \geq 1, \\ 0 < \alpha_i < C &\Leftrightarrow y_i u_i = 1, \\ \alpha_i = C &\Leftrightarrow y_i u_i \leq 1. \end{aligned} \qquad (12)$$

由前面的停止条件3可知，对可行间隙贡献最大的点是那些

$$Gap_i = \alpha_i(y_i(\sum_{j=1}^{n} \alpha_j y_i K(x_i, x_j)) - 1) + C\xi_i = \alpha_i(y_i u_i - 1 - y_i b)) + C\xi_i$$

其中，$\xi_i = max(0, 1 - y_i u_i)$

取值大的点，这些点导致可行间隙变大，因此应该首先优化它们(原因见原博文：http://www.cnblogs.com/vivounicorn/archive/2011/06/01/2067496.html)

SMO的启发式选择有两个策略：

启发式选择**1**：

最外层循环，首先，在所有样本中选择违反KKT条件的一个乘子作为最外层循环，用"启发式选择2"选择另外一个乘子并进行这两个乘子的优化，接着，从所有非边界样本中选择违反KKT条件的一个乘子作为最外层循环，用"启发式选择2"选择另外一个乘子并进行这两个乘子的优化(之所以选择非边界样本是为了提高找到违反KKT条件的点的机会)，最后，如果上述非边界样本中没有违反KKT条件的样本，则再从整个样本中去找，直到所有样本中没有需要改变的乘子或者满足其它停止条件为止。

启发式选择2：

内层循环的选择标准可以从下式看出：

$$\alpha_2^{new} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta}$$

要加快第二个乘子的迭代速度，就要使$\alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta}$最大，而在$\eta$上没什么文章可做，于是只能使$|E_1 - E_2|$最大。

确定第二个乘子方法：

1、首先在非界乘子中寻找使得$|E_1 - E_2|$最大的样本；

2、如果1中没找到则从随机位置查找非界乘子样本；

3、如果2中也没找到，则从随机位置查找整个样本(包含界上和非界乘子)。

(7)、关于两乘子优化的说明

由式子

$$\frac{\partial W(\alpha_2)}{\partial \alpha_2} = -s + 1 + sK_{11}\gamma - K_{11}\alpha_2 - K_{22}\alpha_2 - s\gamma K_{12} + 2K_{12}\alpha_2 + y_2 v_1 - y_2 v_2$$

可知：

$$\frac{\partial W^2(\alpha_2)}{\partial \alpha_2^2} = -K_{11} - K_{22} + 2K_{12} = -\eta$$

于是对于这个单变量二次函数而言,如果其二阶导数$-\eta<0$，则二次函数开口向下，可以用上述迭代的方法更新乘子，如果$-\eta \geq 0$，则目标函数只能在边界上取得极值(此时二次函数开口向上)，换句话说，SMO要能处理η取任何值的情况，于是在$-\eta \geq 0$时有以下式子：

1、$\alpha_2^{new,clipped} = L$时：

$$\alpha_1^{new} = \alpha_1^{old} + s(\alpha_2^{old} - L)$$

2、$\alpha_2^{new,clipped}=H$时：

$$\alpha_1^{new}=\alpha_1^{old}+s(\alpha_2^{old}-H)$$

3、$$W(\alpha_1,\alpha_2)=\sum_{i=1}^n\alpha_i-\frac{1}{2}\sum_{i=1}^n\sum_{j=1}^n y_iy_jK(x_i,x_j)\alpha_i\alpha_j$$

$$=\alpha_1+\alpha_2-\frac{1}{2}K_{11}\alpha_1^2-\frac{1}{2}K_{22}\alpha_2^2-y_1y_2K_{12}\alpha_1\alpha_2-y_1\alpha_1v_1-y_2\alpha_2v_2+\text{constant}$$

$$=\alpha_1(1-y_1v_1)+\alpha_2(1-y_2v_2)-\frac{1}{2}K_{11}\alpha_1^2-\frac{1}{2}K_{22}\alpha_2^2-y_1y_2K_{12}\alpha_1\alpha_2+\text{constant}$$

$$=\alpha_1(1-y_1v_1)+\alpha_2(1-y_2v_2)-\frac{1}{2}K_{11}\alpha_1^2-\frac{1}{2}K_{22}\alpha_2^2-y_1y_2K_{12}\alpha_1\alpha_2+\text{constant}$$

$$=\alpha_1y_1(y_1-(f(x_1)-\alpha_1y_1K_{11}-\alpha_2y_2K_{12}-b))+\alpha_2y_2(y_2-(f(x_2)-\alpha_1y_1K_{12}-\alpha_2y_2K_{22}-b))$$

$$-\frac{1}{2}K_{11}\alpha_1^2-\frac{1}{2}K_{22}\alpha_2^2-y_1y_2K_{12}\alpha_1\alpha_2+\text{constant}$$

$$=\alpha_1^{new}(y_1(b-E_1)+\alpha_1^{old}K_{11}+s\alpha_2^{old}K_{12})+\alpha_2^{new,clipped}(y_2(b-E_2)+\alpha_2^{old}K_{22}+s\alpha_1^{old}K_{12})$$

$$-\frac{1}{2}K_{11}\alpha_1^{new2}-\frac{1}{2}K_{22}\alpha_2^{new,clipped2}-y_1y_2K_{12}\alpha_1^{new}\alpha_2^{new,clipped}+\text{constant}$$

分别将乘子带入得到两种情况下的目标函数值：W_L和W_H。显然，哪种情况下目标函数值最大，则乘子就往哪儿移动，如果目标函数的差在某个指定精度范围内，说明优化没有进展。

另外发现，每一步迭代都需要计算输出u进而得到E，于是还要更新阈值b，使得新的乘子α_1、α_2满足KKT条件，考虑α_1、α_2至少有一个在界内，则需要满足$0\le\alpha_i\le C\Leftrightarrow y_iu_i=1$，于是$b$的迭代可以这样得到：

1、设α_1^{new}在界内，则：

$$y_1u_1^{new}=1\Rightarrow y_1(\alpha_1^{new}y_1K_{11}+\alpha_2^{new,clipped}y_2K_{21}+\sum_{i=3}^n(\alpha_iy_iK_{i1})+b^{new})=1$$

又因为：

$$E_1=\alpha_1^{old}y_1K_{11}+\alpha_2^{old}y_2K_{21}+\sum_{i=3}^n(\alpha_iy_iK_{i1})+b^{old}-y_1$$

$$\Rightarrow\sum_{i=3}^n(\alpha_iy_iK_{i1})=E_1-\alpha_1^{old}y_1K_{11}-\alpha_2^{old}y_2K_{21}-b^{old}+y_1$$

于是有：

$$y_1(\alpha_1^{new}y_1K_{11}+\alpha_2^{new,clipped}y_2K_{21}+\sum_{i=3}^n(\alpha_iy_iK_{i1})+b^{new})$$

$$=y_1(\alpha_1^{new}y_1K_{11}+\alpha_2^{new,clipped}y_2K_{21}+E_1-\alpha_1^{old}y_1K_{11}-\alpha_2^{old}y_2K_{21}-b^{old}+y_1+b^{new})=1$$

等式两边同乘y_1后移项得：

$b^{new} = -\alpha_1^{new} y_1 K_{11} - \alpha_2^{new,clipped} y_2 K_{21} - E_1 + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old}$

$= (\alpha_1^{old} - \alpha_1^{new}) y_1 K_{11} + (\alpha_2^{old} - \alpha_2^{new,clipped}) y_2 K_{21} - E_1 + b^{old}$；

2、设$\alpha_2^{new,clipped}$在界内，则：

$b^{new} = (\alpha_1^{old} - \alpha_1^{new}) y_1 K_{12} + (\alpha_2^{old} - \alpha_2^{new,clipped}) y_2 K_{22} - E_2 + b^{old}$；

3、设α_1^{new}、$\alpha_2^{new,clipped}$都在界内，则：情况1和情况2的b值相等，任取一个；

4、设α_1^{new}、$\alpha_2^{new,clipped}$都不在界内，则：b^{new}取值为情况1和情况2之间的任意值。

(8)、提高**SMO**的速度

从实现上来说，对于标准的SMO能提高速度的地方有：

1、能用缓存的地方尽量用，例如，缓存核矩阵，减少重复计算，但是增加了空间复杂度；

2、如果SVM的核为线性核时候，可直接更新w，毕竟每次计算$w = \sum_{i=1}^{n} y_i \alpha_i x_i$的代价较高，于是可以利用旧的乘子信息来更新$w$，具体如下：

$w^{new} = w^{old} + (\alpha_1^{new} - \alpha_1^{old}) y_1 x_1 + (\alpha_2^{new} - \alpha_2^{old}) y_2 x_2$，应用到这个性质的例子可以参见SVM学习——Coordinate Desent Method。

3、关注可以并行的点，用并行方法来改进，例如可以使用MPI，将样本分为若干份，在查找$|E_1 - E_2|$最大的乘子时可以现在各个节点先找到局部最大点，然后再从中找到全局最大点；又如停止条件是监视对偶间隙，那么可以考虑在每个节点上计算出局部可行间隙，最后在master节点上将局部可行间隙累加得到全局可行间隙。

分类: 基础机器学习算法

标签: SMO

« 上一篇：排序算法汇总总结
» 下一篇：C++虚函数表机制解析(转)

评论

#1楼

写的很好！

2013-11-20 15:38 | 否定之否定心得

注册用户登录后才能发表评论，请 登录 或 注册，访问网站首页。

最新IT新闻:
· 微软图像识别系统准确率跃居第一 击败谷歌
· 最新研究：发短信的时候带标点显得不真诚
· 变形金刚？澳大利亚启用最新款消防机器人
· 微软喊你来投票选择Win 10的内置小游戏！
· 超值福利：Oculus Rift免费捆绑科幻游戏大作
» 更多新闻...

最新知识库文章:
· Linux概念架构的理解
· 从涂鸦到发布——理解API的设计过程
· 好的架构是进化来的，不是设计来的
· 被误解的MVC和被神化的MVVM
· 再谈设计和编码
» 更多知识库文章...